

AI EXAM STUDY GUIDE

人工智能考试样题及参考答案

基础概念 · 前沿主题 · *PyTorch* 编程

依据截图逐题整理，答案按考试作答逻辑编写，可直接编辑、增删与打印。

说明：开放题答案为参考范例，考试时可结合个人经历与课程表述调整。

快速索引

目录

快速索引 2

第〇套【官网版】唯一参考样题 3

 1. 基础题：人工智能的定义、日常应用与局限 4

 2. 基础题：图灵测试及其局限 5

 3. 基础题：神经网络类型与 Transformer 核心机制 6

 4. 前沿题：AI Agent、应用案例与风险 7

 5. 前沿题：多模态 AI、应用场景与挑战 8

 6. 前沿题：大语言模型幻觉、成因与缓解 9

 7. 编程改错题：神经网络测试模式设置（Dropout） 10

 补充知识——BatchNorm 12

 8. 编程理解题：构建简单 CNN 图像分类模型 13

 补充知识：CNN 特征图尺寸计算 14

 考前速记清单 15

第一套【回忆版】考题 17

 第 1 题 弱人工智能、强人工智能和超人工智能 17

 第 2 题 深度学习系统的流程与排查 18

 第 3 题 自然语言理解的困难 19

 第 4 题 图像分类目标检测和图像分割 20

 第 5 题 多模态理解与具身智能 21

 第 6 题 人工智能模型的风险 22

 第 7 题 简单循环神经网络纠错 23

 第 8 题 简单循环神经网络代码补全 24

第二套【回忆版】考题 25

 第 1 题 人工智能概念与学科应用 25

 第 2 题 神经网络结构与召回率精确率 26

第 3 题 长上下文与检索增强生成	27
第 4 题 图像分类目标检测和图像分割	28
第 5 题 具身智能完成拿苹果任务	29
第 6 题 人工智能智能体的应用与隐患	30
第 7 题 训练模式与梯度清零	31
第 8 题 推理模式与设备迁移	32
第三套【回忆版】考题	33
第 1 题 性能良好与稳定可靠	33
第 2 题 数据规模与数据代表性	34
第 3 题 面向文本的人工智能处理流程	35
第 4 题 人工智能角色扮演的三种实现方案	36
第 5 题 生成式视觉模型与判别式视觉模型	37
第 6 题 人工智能伦理与群体指标	38
第 7 题 数据标准化中的信息泄露	39
第 8 题 三层多层感知机代码补全	40
考前检查清单	41
第四套【回忆版】考题	42
第 1 题 预测正确与理解正确	42
第 2 题 神经网络训练流程与损失排查	43
第 3 题 文本分类与信息提取	44
第 4 题 多模态信息融合与对齐	45
第 5 题 人工智能安全风险评估	46
第 6 题 像素通道分辨率与计算成本	47
第 7 题 神经网络测试模式纠错	48
第 8 题 精确率召回率和 F1 计算	49
考前检查清单	49

使用建议：只记住“关键得分点”，编程题应理解张量形状和训练/测试模式，而非只记代码。

第○套【官网版】唯一参考样题

1. 基础题：人工智能的定义、日常应用与局限

请简要定义人工智能（AI），并列举两个你在日常生活中接触过的人工智能应用（如语音助手、推荐系统、人脸识别等）。针对其中一个应用，说明它目前存在的主要局限性（如隐私、误判、偏见等）。

建议作答角度

1. 用自己的话说明人工智能主要能够处理什么问题、表现出哪些能力；
2. 分别列举两个日常生活中的应用，并简要说明它们分别能帮助人们完成什么事情；
3. 从其中一个应用出发，分析至少一项现实局限，以及该局限可能造成的影响。

答题要求：建议作答字数 200~300 字；建议作答时长 10 分钟。

参考答案（考场作答版）

（1）人工智能是让计算机通过数据和算法模拟人类部分智能活动的技术，目前能够完成感知、识别、学习、推理、预测、生成内容、辅助决策等任务。

（2）我日常接触较多的应用有语音助手和短视频推荐系统。

语音助手先识别用户语音，再理解意图，可用于查询天气、设闹钟、导航或控制家电；推荐系统则根据观看、点赞、停留时间等行为预测兴趣，为用户筛选内容。

（3）以推荐系统为例，它的局限包括隐私风险和算法偏见：大量收集行为数据可能造成信息泄露；若训练数据或反馈机制有偏差，系统会不断推送相似内容，形成“信息茧房”，甚至放大刻板印象。因此应加强数据最小化、用户授权、可解释推荐和人工监督。

关键得分点

- 定义要覆盖“数据/算法”与“感知、学习、推理、决策”等能力。
- 两个应用都要说明具体用途，不能只列名称。
- 局限应写清原因、影响和改进方向。

2. 基础题：图灵测试及其局限

用一段话解释什么是图灵测试，简要说明它为何不能完全等同于智能的判定标准。

建议作答角度

1. 说明测试中有哪些参与者、参与者之间通过什么方式交流，以及判断机器是否通过测试的基本依据；
2. 从外在表现是否等于真正理解或具备智能的角度，分析图灵测试存在的局限。

答题要求：建议作答字数 200 字；建议作答时长 10 分钟。

参考答案（考场作答版）

（1）图灵测试由艾伦·图灵提出，通常由一名人类评判者通过文字界面，分别与一名人类和一台机器进行多轮交流。评判者看不到对方身份；如果他不能可靠地区分机器与人，机器就被认为在该测试条件下表现出了类人的会话能力。

（2）它不能完全等同于智能的判定标准，因为测试主要衡量外在语言模仿，而不直接检验机器是否真正理解语义、具有常识、因果推理、意识或在现实环境中行动的能力。结果还会受评判者水平、提问范围、测试时长和机器的回避策略影响。一个系统可能靠话术、记忆或欺骗通过测试，也可能因表达方式不同而未通过。因此，通过图灵测试只能说明“在特定交流中像人”，不能证明其拥有全面、通用的智能。

关键得分点

- 参与者：评判者、人类、机器；通常通过文字交流。
- 判断依据：评判者能否可靠识别机器。
- 核心局限：行为像人不等于真正理解，更不等于通用智能。

3. 基础题：神经网络类型与 Transformer 核心机制

请简述主流神经网络模型的主要类型，并说明构建 Transformer 及现代语言模型所依赖的核心基础组件或机制。

建议作答角度

1. 列举若干主流神经网络类型，可同时写出中文名称和英文简称；
2. 说明 Transformer 在处理一段文字或序列时，如何建立不同位置内容之间的联系；
3. 从“文字如何表示”“顺序如何体现”“信息如何反复加工”等角度，说明现代语言模型需要的基础组成部分或机制。

答题要求：建议作答字数 200~300 字；建议作答时长 10 分钟。

参考答案（考场作答版）

（1）前馈神经网络/多层感知机（FNN/MLP）、卷积神经网络（CNN）、循环神经网络（RNN）、LSTM、GRU 变体、Transformer。

（2）Transformer 先将文本分词并映射为 token 嵌入，再加入位置编码或旋转位置编码，使模型知道词的身份与顺序。核心是多头自注意力：每个位置生成查询 Q、键 K、值 V，用 Q 与其他位置 K 的相似度计算权重，再对 V 加权汇总，从而建立长距离依赖。每层还包含前馈网络、残差连接和层归一化，经过多层反复加工形成上下文表示。

（3）生成式语言模型通常采用带因果掩码的解码器结构，只关注当前位置之前的信息，并通过线性层与 Softmax 预测下一个词元；在大规模语料上进行自监督预训练后，再经指令微调和对齐以提升可用性与安全性。

关键得分点

- 类型至少覆盖 MLP、CNN、RNN 和 Transformer。
- 核心链路：分词/嵌入 → 位置信息 → 自注意力 → 前馈网络与残差归一化。
- 生成模型还需说明因果掩码和下一词元预测。

4. 前沿题：AI Agent、应用案例与风险

当前人工智能正在从“回答问题的模型”逐渐发展到能够调用工具、规划步骤并执行任务的 AI Agent。请解释什么是 AI Agent，并说明它与普通聊天机器人的主要区别。请举一个实际应用案例，并分析使用 Agent 时可能面临的风险。

建议作答角度

1. 说明 AI Agent 如何围绕一个目标获取信息、制定步骤、使用工具并根据结果调整；
2. 从“是否只能回答问题”“能否执行外部操作”“能否完成多步骤任务”等角度，将其与普通聊天机器人进行比较；
3. 给出完整应用案例，说明其任务目标、主要执行步骤、使用的工具及最终结果；
4. 分析至少一项可能风险，并说明这种风险可能产生的后果。

答题要求：建议作答字数 200~300 字；建议作答时长 15 分钟。

参考答案（考场作答版）

（1）AI Agent 是以目标为驱动的智能体。它能感知用户需求和环境状态，将目标分解为步骤，调用搜索、数据库、代码、邮件或业务系统等工具，并根据执行结果持续修正计划，直至完成任务。

（2）普通聊天机器人主要生成回答，通常不直接改变外部世界；Agent 则具有规划、多轮记忆、工具调用和执行外部操作的能力。

（3）以差旅规划 Agent 为例：用户给出城市、日期、预算和偏好后，Agent 搜索航班与酒店，比较价格和时长，生成行程，在获得用户确认后调用预订与支付接口，最后把订单写入日历并发送提醒。

（4）主要风险是模型误判或权限过大，例如选错日期、把虚构价格当成真实库存，甚至未经确认付款，造成经济损失和隐私泄露。因此需采用最小权限、关键操作二次确认、结果校验、日志审计和人工接管机制。

关键得分点

- **Agent 的闭环：目标 → 规划 → 工具执行 → 观察结果 → 调整。**
- **与聊天机器人相比，关键区别在于能否执行外部操作并完成多步骤任务。**
- **案例必须写出目标、步骤、工具、结果；风险要写后果与控制措施。**

5. 前沿题：多模态 AI、应用场景与挑战

请简要解释多模态 AI 的含义，并举例说明其在现实中的一个应用场景。相比于单一模态 AI，多模态 AI 面临的主要挑战是什么？

建议作答角度

1. 说明“多模态”中的“多”指哪些不同形式的信息，以及这些信息如何共同参与任务；
2. 选择一个应用案例，具体说明其中至少两种信息形式分别发挥了什么作用；
3. 从不同信息之间如何对应和配合、数据获取、结果质量、计算成本等角度，分析至少两项技术挑战。

答题要求：建议作答字数 200~300 字；建议作答时长 15 分钟。

参考答案（考场作答版）

（1）多模态 AI 是能够同时处理并融合文本、图像、语音、视频、传感器数据等多种信息形式的人工智能。不同模态既可互相补充，也可共同完成理解、推理和生成任务。

（2）例如自动驾驶系统中，**摄像头图像**用于识别车道线、交通灯和行人；**激光雷达或毫米波雷达**提供物体距离、速度和三维位置；**地图与 GPS** 提供道路结构和定位，融合后帮助车辆规划路线并控制转向、制动。

（3）相比单一模态，多模态 AI 的挑战包括：

第一，不同数据在时间、空间和语义上必须准确对齐，一旦传感器延迟、遮挡或信息冲突，融合结果可能出错；

第二，高质量配对数据难获取，标注成本高且存在隐私问题；

第三，模型参数量和计算量更大，对实时性、能耗和硬件要求更高。此外，还需评估每种模态对结果的贡献，避免模型过度依赖某一种输入。

关键得分点

- 定义要体现“多种信息形式的联合处理与融合”。
- 案例至少说明两种模态各自的作用。
- 挑战可写对齐与融合、数据与标注、冲突鲁棒性、计算成本和评估。

6. 前沿题：大语言模型幻觉、成因与缓解

什么是大语言模型中的“幻觉”（Hallucination）现象？请分析其可能产生的原因（至少两点），并简述一种目前常用的缓解策略。

建议作答角度

1. 说明“幻觉”生成的内容表面有什么特点，以及它与真实事实间可能存在什么问题；
2. 从模型生成内容的方式、学习数据、用户提供的信息、知识时效等不同角度，分析至少两种可能原因；
3. 提出一种缓解方法，并说明该方法为什么能够减少错误，而不是只写出方法名称。

答题要求：建议作答字数 200~300 字；建议作答时长 15 分钟。

参考答案（考场作答版）

（1）大语言模型的“幻觉”是指模型生成的内容语句流畅、形式可信，甚至给出具体数据或引用，但事实错误、无法验证，或与用户提供的材料矛盾。

（2）原因至少有三类：

其一，模型本质上根据上下文预测下一个词元，目标是生成高概率文本，而不是直接查询事实数据库；

其二，训练数据可能包含错误、偏见、矛盾或过时信息，模型的知识也存在截止时间；

其三，当问题含糊、资料不足或要求超出知识范围时，模型可能为保持连贯而补全不存在的细节。

（3）常用缓解策略是**检索增强生成（RAG）**：回答前先从可信、最新的文档库检索相关证据，把证据连同问题输入模型，并要求标注来源、仅依据材料作答或在证据不足时明确说“不确定”。这样能把生成过程约束在可核验信息上，便于用户复查，降低无依据编造。

关键得分点

- 幻觉的特征是“看似合理但事实错误或无法核验”。
- 原因至少写两点，并分别从生成机制、训练数据、提示信息或时效性展开。
- 缓解方法要解释机制；RAG、工具核验、多模型复核、人工审核均可。

7. 编程改错题：神经网络测试模式设置（Dropout）

某同学训练一个用于图像分类的神经网络，为减少过拟合，模型中使用 Dropout 层。模型定义如下：

```
class SimpleNet(nn.Module):  
    def __init__(self):  
        super().__init__()  
        self.fc1 = nn.Linear(100, 64)  
        self.dropout = nn.Dropout(p=0.5)  
        self.fc2 = nn.Linear(64, 10)  
    def forward(self, x):  
        x = F.relu(self.fc1(x))  
        x = self.dropout(x)  
        x = self.fc2(x)  
        return x
```

训练完成后，同学使用下面的代码在测试集上进行预测：

```
correct = 0  
total = 0  
with torch.no_grad():  
    for x, y in test_loader:  
        outputs = model(x)  
        _, predicted = torch.max(outputs, 1)  
        total += y.size(0)  
        correct += (predicted == y).sum().item()  
accuracy = correct / total
```

已知 Dropout 在训练阶段会随机关闭一部分神经元，在测试阶段应关闭这种随机行为；`model.eval()` 可以将模型切换到评估模式。请回答：

①上述测试代码存在什么问题？【分析模型当前所处的运行状态；该状态下 Dropout 的随机行为为什么会导致两次输出不同】

②请修改下面代码，使模型按照正确方式进行测试。

```
correct = 0
```

```
total = 0
with torch.no_grad():
    for x, y in test_loader:
        outputs = model(x)
        _, predicted = torch.max(outputs, 1)
        total += y.size(0)
        correct += (predicted == y).sum().item()

accuracy = correct / total
print("Test Accuracy:", accuracy)
```

③测试完成后，如果还需要继续训练模型，应执行什么操作？【说明完成测试后，如果还需要继续训练模型，应进行什么状态恢复操作】

答题要求：建议作答时长 20 分钟。

参考答案（考场作答版）

（1）训练结束后，模型默认仍处于训练模式（`model.training == True`）。此时即使进入 `torch.no_grad()` 也只关闭自动求导和梯度记录，并不会把 Dropout 或 BatchNorm 切换到推理行为。因此 Dropout 仍会随机丢弃神经元，同一输入多次前向传播可能得到不同输出，测试准确率也会波动。测试前必须调用 `model.eval()`。

Dropout 随机性的影响：测试阶段需要对样本得到确定、稳定的预测结果。如果 Dropout 开启，同一个输入 `x` 两次传入模型时，被随机丢弃的神经元不同，得到的输出 `outputs` 也会不同，最终预测结果 `predicted` 不稳定，计算出的准确率会波动，无法反映模型真实的泛化能力。并且 Dropout 训练时的缩放逻辑（训练时丢弃后对激活值除以 `1-p`）也不会在推理时自动适配，导致输出的数值量级错误

（2）修改后的正确测试代码：测试前先调用 `model.eval()` 切换到评估模式，此时 Dropout 层会自动失效（相当于保留全部神经元，且自动对权重乘以 `1-p` 做缩放），同时 BatchNorm 也会使用训练阶段统计的全局均值/方差而非当前批次统计量。

```
model.eval() # 切换到评估模式，关闭 Dropout 的随机丢弃行为

correct = 0
total = 0
....【后续不变】
```

(3) 继续训练：测试完成后执行 `model.train()`，将 Dropout、BatchNorm 等层恢复为训练模式，然后再进行反向传播和参数更新。如果不调用该方法直接继续训练，Dropout 会一直失效，模型无法起到正则化作用，容易过拟合；BatchNorm 也会错误使用批次统计量更新全局参数，导致训练异常。

关键得分点

- `model.eval()` 与 `torch.no_grad()` 作用不同，正确测试时通常两者都要使用。
- `model.eval()` 改变 Dropout/BatchNorm 的运行方式；`torch.no_grad()` 只控制梯度记录。

补充知识——BatchNorm

BatchNorm 全称 **Batch Normalization**（批归一化 / 批量归一化），是神经网络里一种“稳定数据分布、加速训练”的层/技巧。

1. BatchNorm 的作用？

问题：神经网络层层传数据。训练时前面层参数在更新，导致后面层收到的数据分布一直变 $\Rightarrow$ 有时均值偏大、有时方差大 $\Rightarrow$ 让训练变慢、不稳定、深层网络易梯度消失/爆炸

解决：BatchNorm 在每一层输入前，先把这一小批数据的分布“拉回”到差不多均值 0、方差 1 的标准状态，再稍微缩放平移一下，让后面层学得更稳更快。【类似标准化】

2. BatchNorm 训练时具体操作？

假设当前小批量 batch 里有一些数值，BatchNorm 对每个特征维度做：

①算当前 batch 的均值、②算当前 batch 的方差、③标准化、④可学习缩放和平移：

3. BatchNorm 为什么训练和测试时行为不同？

这是重点，也是为什么 `model.eval()` 重要的原因。

训练模式：`model.train()`

用当前 batch 的均值/方差做归一化；同时更新 `running_mean`、`running_var`；

因为每个 batch 不同，所以有轻微随机性，也有一点正则化效果

评估/测试模式：`model.eval()`

不再用当前测试 batch 的均值/方差；改用训练阶段积累好的 `running_mean`、`running_var`（不更新）；输出更稳定、确定，同样输入结果一致

如果测试时不切换到 `eval()`，BatchNorm 会拿测试 batch 自己算均值方差，导致：

同一样本不同 batch 里结果可能不同；测试指标抖动；如果 batch 很小，统计更不可靠

BatchNorm 就是在每层旁边做“批内标准化”，训练时用当前 batch 统计并积累全局统计，测试时用训练好的全局统计，配合 `model.eval()/model.train()` 控制行为，让训练更稳更快，测试更确定。

8. 编程理解题：构建简单 CNN 图像分类模型

某研究小组使用卷积神经网络 CNN 对图片进行分类。输入图片大小为 $3 \times 32 \times 32$ ，3 表示 RGB 三个颜色通道、 32×32 表示图片尺寸，共识别 10 个类别。设计如下网络：

输入($3 \times 32 \times 32$) $\rightarrow$ Conv1(3 通道 $\rightarrow$ 8 通道) $\rightarrow$ ReLU $\rightarrow$ 2×2 MaxPool
 $\rightarrow$ Conv2(8 通道 $\rightarrow$ 16 通道) $\rightarrow$ ReLU $\rightarrow$ 2×2 MaxPool $\rightarrow$ Flatten $\rightarrow$ Linear $\rightarrow$ 输出 10 个类

为帮助完成程序，现给出第一个卷积层的完整写法：

```
# 第一层已给出
self.conv1 = nn.Conv2d(
    in_channels=3,
    out_channels=8,
    kernel_size=3,
    padding=1
)
# 请参照第一层补全第二层
self.conv2 = nn.Conv2d(
    in_channels=( 1 ),
    out_channels=( 2 ),
    kernel_size=3,
    padding=1
)
self.pool = nn.MaxPool2d(2)
# 两次池化后，将特征展开并输入全连接层
self.fc = nn.Linear( ( 3 ), 10 )

def forward(self, x):
    # Conv1  $\rightarrow$  ReLU  $\rightarrow$  Pool
    x = self.pool(F.relu(self.conv1(x)))
    # Conv2  $\rightarrow$  ReLU  $\rightarrow$  Pool
    x = self.pool(F.relu(( 4 )))
    x = torch.flatten(x, 1)
    x = self.fc(x)
    return x
```

答题要求：在空白处填写代码；建议作答时长 25 分钟。

填空答案

空号	答案	理由
(1)	8	第二层卷积接收第一层输出的 8 个通道。
(2)	16	题目指定 Conv2 输出 16 个通道。
(3)	1024	两次 2×2 池化使 $32 \rightarrow 16 \rightarrow 8$ ，通道数为 16。卷积层使用 <code>kernel_size=3</code> 、 <code>padding=1</code> 不改变空间尺寸；第一次池化后为 $8 \times 16 \times 16$ ，第二次池化后为 $16 \times 8 \times 8$ ，展平后特征数 $= 16 \times 8 \times 8$
(4)	<code>self.conv2(x)</code>	第二个池化层先执行 Conv2，再执行 ReLU 和 Pool。

尺寸推导：卷积层使用 `kernel_size=3`、`padding=1`，因此不改变空间尺寸；第一次池化后为 $8 \times 16 \times 16$ ，第二次池化后为 $16 \times 8 \times 8$ ，展平后特征数为 $16 \times 8 \times 8 = 1024$ 。

补充知识：CNN 特征图尺寸计算

一、通用符号约定		
符号	含义	说明
H_{in}, W_{in}	输入高、宽	如 32×32
K	<code>kernel_size</code> (卷积核大小)	常见 3、5、7；若 $K_h \neq K_w$ 需分开写
P	<code>padding</code> (填充)	四周各补 P 行/列
S	<code>stride</code> (步长)	默认 1
D	<code>dilation</code> (空洞/膨胀率)	默认 1 (不膨胀)
C_{in}	输入通道数	如 RGB 为 3
C_{out}	输出通道数	卷积层 <code>out_channels</code>
关键原则： 通道维度不参与空间尺寸计算。 <code>Conv2d(Cin, Cout, ...)</code> 只改变通道数，空间高宽由 K, P, S, D 决定。		
1. Conv2d (标准卷积) $H_{out} = \left\lfloor \frac{H_{in} + 2P - D(K - 1) - 1}{S} \right\rfloor + 1$ • 当 $D = 1$ (无空洞) 时简化为： $H_{out} = \left\lfloor \frac{H_{in} + 2P - K}{S} \right\rfloor + 1$		2. MaxPool2d / AvgPool2d (池化) 池化 不改变通道数 ，公式与卷积相同 (可视为 $D = 1$ 的特例)： $H_{out} = \left\lfloor \frac{H_{in} + 2P - K}{S} \right\rfloor + 1$ • 常见 <code>nn.MaxPool2d(2)</code> ：即 $K = 2, S = 2, P = 0 \rightarrow$ 尺寸 减半 • 常见 <code>nn.MaxPool2d(2, stride=1)</code> ：尺寸几乎不变

3. ConvTranspose2d (转置卷积 / 反卷积, 上采样) $H_{out} = (H_{in} - 1) S - 2P + K + P_{out}$ 其中 P_{out} 为 <code>output_padding</code> (通常 0 或用于对齐)。简化 (忽略 P_{out}) : $H_{out} \approx (H_{in} - 1) S + K - 2P$ • 作用: 放大特征图尺寸 (用于语义分割、GAN 生成器等)	4. Flatten (展平) 只改变形状, 不改变元素总数: 展平后维度 = $C \times H \times W$		
层	通道变化	空间尺寸计算	输出 shape
输入	3	32×32	[3, 32, 32]
Conv1 (k3,p1,s1)	3→8	$32 + 2 - 3 + 1 = 32$	[8, 32, 32]
MaxPool(2)	8	$32/2 = 16$	[8, 16, 16]
Conv2 (k3,p1,s1)	8→16	16	[16, 16, 16]
MaxPool(2)	16	$16/2 = 8$	[16, 8, 8]
Flatten	—	$16 \times 8 \times 8 = 1024$	1024
Linear	1024→10	—	10

考前速记清单

- 人工智能：数据 + 算法；感知、学习、推理、生成、决策。
- 图灵测试：测“像不像人”，不等于测“是否真正理解”。
- Transformer：嵌入、位置、自注意力、前馈网络、残差与归一化。
- AI Agent：目标驱动、规划、工具调用、执行、反馈闭环。
- 多模态：对齐、融合、数据、成本、鲁棒性。
- 幻觉：流畅但错误；用检索、引用、核验和人工审核降低风险。
- PyTorch 测试：`model.eval() + torch.no_grad()`；继续训练用 `model.train()`。
- CNN 尺寸：通道看上一层输出，池化使高宽减半，Flatten 后相乘。

人工智能分层考试新增考题及 参考答案【回忆版】

三套考题 十八道问答题 六道编程题

用于概念复习、答题结构训练和 PyTorch 代码检查

第一套【回忆版】考题

题目来源：20260907 珠海批次考试考题回忆版

第1题 弱人工智能、强人工智能和超人工智能

题目 说明弱人工智能、强人工智能和超人工智能的区别。解释为什么一个系统在某项任务上表现非常出色，仍不能据此称为强人工智能，并举例说明。

参考答案

(1) 弱人工智能（计算智能），它围绕明确任务训练，只能在限定输入、人工定义的严格规则和环境工作中，例如围棋程序 AlphaGo、大数据存储与计算、AI 剪枝优化决策。它可能在单项指标上超过人类，但不会自动把这种能力迁移到无关任务。

(2) 强人工智能（感知智能），受限环境下的感知，如自动驾驶、人脸识别。指具有接近人类的通用学习、理解、推理和适应能力，能在陌生领域利用已有知识解决新问题。

(3) 超人工智能（认知智能），是指与人的交流、交融，具备自然语言理解、知识推理能力，其综合认知能力在科学研究、创造、社会判断等多数重要领域持续超过最优秀人类。

(4) 单项任务表现强不等于通用智能，更不等于强人工智能，因为成绩可能来自海量训练、精确规则或对固定数据分布的优化。围棋程序能搜索局面并选择落子，却不能因此理解交通法规、照顾病人或解释一则新闻。只要任务、输入格式或环境发生较大变化，它可能立即失效。判断强人工智能应考察跨任务迁移、常识、因果推理、自主学习和在真实环境中的稳定适应，而不能只看一项排行榜成绩。

评分要点

- 准确区分专用能力、通用能力和假设中的超人能力。
- 说明高性能可能来自窄任务优化，不能自动迁移。
- 例子要同时写出擅长任务和无法完成的其他任务。

第2题 深度学习系统的流程与排查

题目 说明深度学习系统从目标定义到最终评估的主要步骤及各自作用。选择至少两个环节，分析设计不准确会造成什么后果。若系统在真实环境中的效果明显变差，你会优先检查哪些模块，并说明理由。

参考答案

（1）完整流程：

针对特定任务（确定目标与指标定义）、 决定系统究竟优化什么
收集相应数据（数据采集、划分、清洗、标注）、 决定模型能看到哪些情况
构建合适模型（模型及损失函数选择）、 决定容量和归纳偏置
利用恰当算法、
实现有效学习（训练与超参数调整）、 验证用于比较方案与抑制过拟合
最终评估（独立测试、部署监测）。 估计对未见数据的泛化能力。

（2）若目标指标定义错误，如只追求总体准确率而忽略少数高风险类别，模型即使分数很高也可能漏掉关键样本。

若训练集与真实场景不一致，模型会学习错误相关性，遇到不同光照、口音或设备便失效。

若验证集被反复用于调参，验证成绩也会被过拟合，最终评估过于乐观。

（3）真实效果下降时，

- ①输入数据管道和分布是否改变，包括传感器、预处理、字段单位和缺失值；
 - ②模型版本、权重、推理模式及阈值是否与测试时一致。
 - ③按时间、地区、设备和类别切分线上样本，定位漂移发生在哪一段，并抽样复核标签。
- 这样可区分数据问题、模型本身泛化问题、部署配置问题。

评分要点

- 流程应覆盖目标、数据、模型、训练、验证、测试和部署监测。
- 至少分析两个环节的误差及其具体后果。
- 排查要从数据管道、模型版本和分群指标入手，并说明原因。

第3题 自然语言理解的困难

题目 说明自然语言理解为什么困难。请从词义歧义、上下文依赖和常识推理等方面作答，并举出一个在不同场景中含义不同的句子。

参考答案

（1）自然语言不是词语含义的简单相加。同一个词可能有多种意义，句法结构也可能对应不同关系。例如“苹果”既可以指水果，也可能指公司。代词、省略、反讽和语气还要求模型利用前后文判断说话人的真正意图。

（2）较长对话中，关键信息可能出现在很早的位置，模型若没有正确保持人物、时间和事件关系，就会作出错误解释。

（3）理解依赖现实世界常识和因果知识。“他把冰块放在阳光下，过了一会儿它不见了”没有直接写出融化，但人能依据常识补全原因。模型若只利用词语共现，可能得到表面相关但不合常理结论。文化背景、行业术语和说话双方共享但未明说的信息，也会改变句意。

（4）例如“这个苹果不行”在水果摊可能表示水果不新鲜，在手机维修店可能表示一部苹果手机故障，在证券讨论中又可能表示对苹果公司股票或业务表现不看好。要正确理解，系统需要结合地点、对话主题、指代对象和用户意图，而不能只依据句子本身。

评分要点

- 至少覆盖词义歧义、上下文依赖和常识推理。
- 例句应在两个或更多场景中产生不同解释。
- 说明模型需要利用场景、历史对话和现实知识消除歧义。

第 4 题 图像分类目标检测和图像分割

题目 区分图像分类、目标检测和图像分割，并说明三者与信息粒度、输出形式和典型应用上的差异。

参考答案

图像分类回答“整张图主要是什么”。输入一幅图像，输出一个或多个类别及概率，例如判断照片是猫、狗还是汽车。它只给全局标签，不说明物体位于哪里，因此信息粒度最粗。多标签分类可判断一张图中是否同时存在若干类别，但通常仍不提供每个实例位置。

目标检测同时回答“是什么”和“在哪里”。模型为每个目标输出类别、置信度和边界框，例如在道路画面中分别框出行人、车辆和交通灯。它能区分多个实例，但矩形框只近似表示位置，无法描述目标的精确轮廓。常见应用包括交通监控、货架盘点和缺陷定位。

图像分割在像素级给出结果，信息粒度最细。语义分割为每个像素分配类别，实例分割还要区分同类目标的不同个体。例如医学影像中勾画肿瘤边界，自动驾驶中标记可行驶区域。三者输出依次为图像级标签、目标级边界框、像素级掩膜，标注成本和计算量通常也依次增加。

评分要点

- 分类输出图像级标签。
- 检测输出类别、置信度和边界框。
- 分割输出像素级掩膜，并可区分语义分割与实例分割。

第5题 多模态理解与具身智能

题目 说明多模态理解与具身智能的区别。按照具身智能的感知、理解、规划、行动、反馈过程举一个通用例子。若系统执行失败，应检查哪些模块，并说明理由。

参考答案

多模态理解侧重联合处理文本、图像、语音、视频等信息，系统可以在计算环境中完成描述、问答或生成，并不必然控制现实设备。具身智能则拥有或连接机器人身体，通过传感器感知物理环境，并把理解转化为运动和操作。它必须处理空间位置、物体接触、动力学、安全约束和实时变化，因此除了认知模型，还依赖硬件、控制和闭环反馈。

以服务机器人把水杯送到桌上为例。感知阶段利用摄像头和深度传感器定位水杯、桌面与障碍物；理解阶段识别指令对象和目标位置；规划阶段选择抓取姿态、机械臂轨迹和移动路线；行动阶段控制底盘、关节和夹爪；反馈阶段根据视觉、力觉和编码器数据判断是否抓稳、是否偏离路线，并实时修正，直到安全放置。

若任务失败，应按现象定位模块。认错物体先查传感器质量、标定和识别模型；路线碰撞要查环境地图、障碍物更新和规划约束；抓取滑落要查姿态估计、夹爪力度与控制器；执行中逐渐偏离则检查反馈频率和坐标转换。逐段记录中间结果能确定错误从哪一环开始传播。

评分要点

- 指出多模态理解不一定行动，具身智能必须与物理环境交互。
- 完整写出感知、理解、规划、行动和反馈。
- 故障排查要把现象对应到传感、规划、控制或反馈模块。

第 6 题 人工智能模型的风险

题目 分别说明人工智能模型的自身风险、外部风险和伦理风险，各举一个例子，并提出相应的缓解方法。

参考答案

自身风险来自模型和数据本身，包括幻觉、误判、分布外失效、偏见和不可解释性。例如医疗问答模型编造不存在的药物禁忌，用户若据此自行用药可能受伤。缓解方法包括使用可靠数据、检索或工具核验、置信度阈值、拒答机制、独立测试和专业人员复核，并持续监测不同人群和场景中的错误率。

外部风险来自攻击者、系统集成和使用环境。例如攻击者通过提示注入诱使智能体泄露内部文件，或利用对抗样本让视觉模型漏检。防护应实行最小权限、输入隔离、敏感信息过滤、身份认证、日志审计和关键操作二次确认；模型输出进入业务系统前还应经过规则校验，避免一条错误指令直接造成外部影响。

伦理风险涉及公平、隐私、责任和人的自主权。例如招聘模型用历史录用数据训练，可能延续对某些群体的不利偏差。组织应评估数据代表性，按群体测量误差，提供申诉和人工复核渠道，明确责任主体，并只收集完成任务所需的数据。技术措施不能代替治理，高影响场景还需要用途限制和定期审查。

评分要点

- 三类风险均要定义并各举一例。
- 说明风险产生的实际后果。
- 措施应与风险一一对应，覆盖技术控制和管理责任。

第 7 题 简单循环神经网络纠错

题目 下面的循环神经网络用于序列分类。输入张量形状为 $\text{batch_size} \times \text{sequence_length} \times \text{input_size}$ ，模型应使用最后一个时间步的隐藏表示输出 num_classes 个类别。代码中全连接层输入维度错误，请指出问题并修正。

参考答案

nn.RNN 的输出 out 形状为 $\text{batch_size} \times \text{sequence_length} \times \text{hidden_size}$ 。取 out[:, -1, :] 后得到 $\text{batch_size} \times \text{hidden_size}$ ，因此全连接层接收的特征数必须是 hidden_size 。原代码若写成 $\text{nn.Linear}(\text{input_size}, \text{num_classes})$ ，当 input_size 与 hidden_size 不相等时，矩阵乘法维度不匹配，程序会在前向传播时报错。

参考代码

```
class RNNClassifier(nn.Module):
    def __init__(self, input_size, hidden_size, num_classes):
        super().__init__()
        self.rnn = nn.RNN(input_size, hidden_size, batch_first=True)
        self.fc = nn.Linear(hidden_size, num_classes) # 修正处

    def forward(self, x):
        out, _ = self.rnn(x)
        last = out[:, -1, :]
        return self.fc(last)
```

评分要点

- 说清 **RNN** 输出的三维形状。
- 指出最后时间步的特征维度是 **hidden_size**。
- 修正为 **nn.Linear(hidden_size, num_classes)**。

第 8 题 简单循环神经网络代码补全

题目 补全一个标准循环神经网络分类器。要求 RNN 按批次优先接收序列，使用最后一个时间步的输出完成分类，并写出三个关键空白。

参考答案

第一个空白是 `nn.RNN(input_size, hidden_size, batch_first=True)`，它把每个时间步的输入映射到 `hidden_size` 维隐藏状态。第二个空白是 `out[:, -1, :]`，表示取每个样本最后一个时间步的输出。第三个空白是 `nn.Linear(hidden_size, num_classes)`，把隐藏表示转换为类别得分。

若序列包含填充，简单取最后位置可能取到填充值，此时应结合真实长度使用 `pack_padded_sequence`，或按长度索引最后一个有效时间步。本题假设所有序列等长，因此直接取 -1 即可。

参考代码

```
class SimpleRNN(nn.Module):
    def __init__(self, input_size, hidden_size, num_classes):
        super().__init__()
        self.rnn = nn.RNN(input_size, hidden_size, batch_first=True) # 空白一
        self.fc = nn.Linear(hidden_size, num_classes) # 空白三

    def forward(self, x):
        out, _ = self.rnn(x)
        x = out[:, -1, :] # 空白二
        return self.fc(x)
```

评分要点

- RNN 设置 `batch_first=True`。
- 分类输入取 `out[:, -1, :]`。
- 全连接层输入维度为 `hidden_size`。

第二套【回忆版】考题

题目来源：20260831 提前批考试考题回忆版

第 1 题 人工智能概念与学科应用

题目 说明人工智能的概念，列举两个学科中的人工智能应用，并分析其中一个应用可能出现的误判、偏见或其他现实问题。

参考答案

人工智能是利用数据、算法和计算资源，使机器完成通常需要人类智能参与的感知、理解、学习、推理、生成和决策任务。它并不是单一学科，而是与计算机、数学、认知科学和具体应用领域结合的技术体系。系统通常从样本中学习模式，再对新输入进行预测或生成，但结果受数据范围、模型目标和使用环境限制。

在医学中，影像辅助诊断模型可从 CT 或病理图像中标出疑似病灶，帮助医生筛查；在教育中，智能辅导系统可分析答题记录，定位知识薄弱点并推荐练习。也可列举气象预测、材料发现、金融风控等应用。每个例子都应说明输入、模型任务和对专业人员的帮助。

以医学影像为例，模型可能把良性组织误判为病灶，造成不必要检查，也可能漏诊真正病灶。若训练数据主要来自某类设备、地区或人群，其他人群的错误率可能更高，形成系统性偏见。应使用多中心数据，按人群和设备分别评估召回率与误报率，提供置信度和可解释证据，并由医生作最终判断。

评分要点

- 定义应包含数据算法和智能任务。
- 两个跨学科应用都要说明具体作用。
- 风险分析要写出原因、后果和控制办法。

第 2 题 神经网络结构与召回率精确率

题目 列举四种神经网络结构，分别说明其组织信息的方式、共同点、差异和典型应用。解释召回率与精确率的含义，并说明在检测资源有限时如何取舍。

参考答案

多层感知机把输入展平为固定长度向量，通过全连接层组合全局特征，常用于表格数据和简单分类。卷积神经网络用局部卷积核共享参数，逐层提取边缘、纹理和空间结构，适合图像分类与检测。循环神经网络按时间顺序更新隐藏状态，保存此前信息，适合短序列、语音和时间序列；LSTM 或 GRU 可缓解长期依赖问题。Transformer 用自注意力让每个位置直接汇聚其他位置的信息，并加入位置编码，适合语言模型、长序列和多模态任务。

四者都通过可训练参数、非线性变换和损失函数从数据中学习表示，训练时使用反向传播。差异主要在连接方式和归纳偏置：MLP 不显式利用空间或顺序；CNN 强调局部与平移结构；RNN 递归处理顺序，难以完全并行；Transformer 建立全局关系，易并行但长序列计算和显存开销较大。

召回率等于真正例中被检出的比例 TP 除以 TP 加 FN ，关注少漏检；精确率等于所有报为正例中真正例的比例 TP 除以 TP 加 FP ，关注少误报。资源有限时应结合错误成本取舍。疾病初筛、安全告警通常优先召回率，再由人工复核误报；人工复核成本很高或一次处置代价很大时，应提高精确率。可通过调整阈值、分级告警和二阶段筛查在资源约束下平衡二者。

评分要点

- 四种结构要写信息组织方式与应用。
- 比较共同训练机制和结构差异。
- 准确写出召回率与精确率公式，并结合漏检误报成本取舍。

第3题 长上下文与检索增强生成

题目 说明把长文本资料直接放入上下文与使用检索增强生成时，信息进入模型的不同流程；分别给出一个优势、一个局限和一个应用。再从 token 消耗、信息干扰、更新方式和证据溯源比较二者，并解释在上下文窗口持续变长时 RAG 为什么不会被完全替代。

参考答案

直接长上下文把全部或大部分资料切分、编码为 token，与问题一起一次性送入模型，模型在注意力计算中寻找相关内容。优势是流程简单，能同时看到跨章节关系，适合审阅一份篇幅可控的合同或完整会议记录；局限是 token 成本和延迟随材料增长，重要证据可能被大量无关内容稀释，超过窗口的内容仍需裁剪。

RAG 先把文档分块并建立向量或关键词索引。收到问题后，检索器找出相关片段，再把问题与少量片段送入模型生成答案。优势是每次只使用相关证据，知识库可独立更新并返回来源，适合企业制度问答或持续变化的产品手册；局限是检索可能漏掉关键片段，分块和排序错误也会限制答案，模型看不到未被召回的内容。

二者相比，长上下文消耗更多 token，容易出现信息干扰；资料更新时需要重新提供完整内容，引用定位也要额外设计。RAG 只传入召回片段，索引可增量更新，通常更便于显示文档名和段落。即使窗口变长，读取全部资料的成本、延迟、权限隔离和噪声不会消失，企业知识还会不断变化。因此 RAG 会与长上下文结合，而不会被完全替代。

评分要点

- 分别说明两条信息进入模型的流程。
- 从四个指定维度完成对比，并各给应用。
- 说明长窗口不能消除成本、噪声、更新和权限问题。

第 4 题 图像分类目标检测和图像分割

题目 区分图像分类、目标检测和图像分割，说明三者回答的问题、输出结果和信息粒度

参考答案

图像分类对整张图片作判断，回答“这张图属于什么类别”。输出通常是类别概率或若干标签，例如判断胸片是否存在异常。它不提供异常位于何处，适合只需要全局判断的任务，所需标注通常也是图像级标签。

目标检测进一步回答“有哪些目标，它们在哪里”。模型为每个实例输出类别、置信度和矩形边界框，例如在街景中框出每辆车和每名行人。检测能表示目标数量和大致位置，但边界框包含背景，不能精确描述轮廓。

图像分割为每个像素输出类别或实例归属，回答“目标的精确区域是什么”。语义分割把同类像素归为一类，实例分割还区分不同个体。它适合肿瘤轮廓、道路区域和工业缺陷面积测量。三者的信息粒度依次为图像级、目标级和像素级；输出依次为标签、边界框和掩膜，标注与计算成本通常也逐步提高。

评分要点

- 写清三类任务分别回答什么问题。
- 输出形式依次为标签、边界框和像素掩膜。
- 指出粒度、标注成本和应用需求的差异。

第5题 具身智能完成拿苹果任务

题目 说明具身智能的概念。以机器人执行“帮我拿一个苹果”为例，从感知、理解、规划、运动和反馈分析实现流程，并解释纯问答人工智能为什么不能完成该任务。

参考答案

具身智能是让智能系统借助机器人身体和传感器，在物理环境中感知、决策和行动，并从交互反馈中调整行为。

收到“帮我拿一个苹果”后，感知模块通过摄像头、深度传感器和位置编码器建立环境表示，识别苹果、桌面、人物和障碍物，同时估计目标三维位置和可抓取姿态。

理解模块解析“苹果”是目标物体，“拿”表示抓取并交给用户，还要根据上下文确认数量和目标人物。

规划模块把任务分解为导航、接近、机械臂预抓取、闭合夹爪、抬起、返回和递交，并选择无碰撞路径。

运动与控制模块把规划转成底盘和关节指令，满足速度、力度和稳定性限制。

反馈模块持续利用视觉和力觉判断苹果是否移动、是否抓稳、用户是否接到，并在失败时重新定位或抓取。

纯问答人工智能只能处理数字信息并生成文字或语音，没有摄像头、机械臂、坐标标定和运动控制接口，无法知道苹果的实时位置，也不能对现实物体施加力。即使它能写出步骤，也缺少执行和反馈闭环。因此完成任务需要语言模型与感知、规划、控制、硬件安全机制共同工作。

评分要点

- 定义应包含身体、环境交互和反馈闭环。
- 按五个指定阶段完整描述任务。
- 说明纯问答系统缺少传感器、执行器和实时控制。

第 6 题 人工智能智能体的应用与隐患

题目 说明 AI Agent 的概念，列举一个实际应用，描述该应用的实现流程，并分析其中可能存在的隐患。

参考答案

AI Agent 是围绕目标持续感知信息、制定计划、调用工具、执行操作并根据结果调整下一步的智能系统。普通聊天模型通常只返回内容，而 Agent 还可能访问搜索、数据库、代码环境、邮件、日历或业务接口，对外部状态产生实际影响。它需要保存任务状态，判断是否完成，并在失败时重试、换工具或请求人工确认。

以差旅助理 Agent 为例，用户提供城市、日期、预算和偏好后，系统先解析约束，再调用航班、酒店和地图接口获取实时数据；随后比较价格、时长与退改规则，生成方案。用户确认后，Agent 才能调用预订和支付接口，把订单写入日历并发送提醒。执行中每一步都应记录输入、工具结果和决策依据。

隐患包括模型误解日期、把过期价格当成实时库存、提示注入诱使系统泄露数据，以及权限过大导致未经确认付款。工具失败后盲目重试还可能产生重复订单。控制措施包括最小权限、可信工具白名单、关键步骤二次确认、金额和日期规则校验、幂等操作、敏感信息隔离、完整日志和人工接管。

评分要点

- 概念包含目标、规划、工具调用、执行和反馈。
- 案例写出输入、步骤、工具和最终结果。
- 隐患要覆盖错误、权限或攻击，并给出对应控制。

第 7 题 训练模式与梯度清零

题目 下面的 PyTorch 训练循环在模型此前执行过 `model.eval()` 的情况下继续训练，并且没有清空梯度。指出缺少的两条语句，解释后果并给出修正代码。

参考答案

训练前缺少 `model.train()`。如果模型仍处于评估模式，Dropout 不再随机丢弃神经元，BatchNorm 也不会按训练批次更新均值和方差，训练行为与设计不一致。每个批次反向传播前还缺少 `optimizer.zero_grad()`。PyTorch 默认把新梯度累加到参数已有的 `grad` 中；若不清空，第二个批次使用的是多个批次梯度之和，更新幅度和方向会偏离预期，甚至造成训练不稳定。

标准顺序是先把模型切换到训练模式；每个批次把数据放到相同设备；清空旧梯度；前向计算和损失；反向传播；最后更新参数。若有意做梯度累积，可以每隔若干批次再 `zero_grad` 和 `step`，同时按累积步数缩放损失，但必须明确设计，不能把遗漏清零当作梯度累积。

参考代码

```
model.train()

for x, y in train_loader:
    x = x.to(device)
    y = y.to(device)

    optimizer.zero_grad()
    outputs = model(x)
    loss = criterion(outputs, y)
    loss.backward()
    optimizer.step()
```

评分要点

- 训练开始前调用 `model.train()`。
- 每次常规反向传播前调用 `optimizer.zero_grad()`。
- 解释 Dropout 或 BatchNorm 模式差异和梯度累计后果。

第 8 题 推理模式与设备迁移

题目 补全 PyTorch 推理代码中的三处关键内容：把模型切换到评估模式、关闭梯度记录，并把输入 `x` 移动到模型所在设备。解释每一步的作用。

参考答案

推理前调用 `model.eval()`，使 Dropout 关闭随机丢弃，并让 BatchNorm 使用训练期间保存的运行均值和方差。`with torch.no_grad()` 关闭梯度图构建，减少显存和计算量，但它不会自动改变 Dropout 或 BatchNorm 的模式，因此不能替代 `model.eval()`。`x.to(device)` 保证输入与模型参数在同一设备，否则常见报错是张量位于不同设备。

若还要计算准确率，标签 `y` 也应移动到 `device`，或把预测结果转回 CPU 后再比较。推理结束后若继续训练，应重新调用 `model.train()`。正式评估还应确保预处理、类别顺序和权重版本与训练时一致，避免代码模式正确但数据流程不同。

参考代码

```
model.eval()

all_predictions = []
with torch.no_grad():
    for x in test_loader:
        x = x.to(device)
        outputs = model(x)
        predictions = outputs.argmax(dim=1)
        all_predictions.append(predictions.cpu())
```

评分要点

- 完整写出 `model.eval()`。
- 使用 `with torch.no_grad()` 包住推理循环。
- 写出 `x = x.to(device)`，并解释设备一致性。

第三套【回忆版】考题

题目来源：20260908 早上计算机专业考题回忆版

第 1 题 性能良好与稳定可靠

题目 说明人工智能系统性能好与稳定可靠的区别，并比较测试环境和实际部署环境。

参考答案

性能好通常指系统在给定测试集和指标上取得较高结果，如准确率、召回率、响应速度或生成质量。稳定可靠则强调系统在时间、地点、设备、用户群体和异常输入变化时，仍能持续给出可接受结果，并在无法处理时安全失败。一次测试得分高只证明模型适合该数据分布，不等于长期运行可靠；可靠性还包括鲁棒性、可用性、可恢复性、可监控性和安全边界。

测试环境往往数据干净、类别比例固定、硬件充足，软件版本和预处理流程也被严格控制。实际部署会遇到光照、口音、传感器、网络延迟、缺失字段和用户行为变化，还可能出现训练中从未见过的输入、恶意攻击及上下游接口故障。线上人群分布也可能改变，使离线总体指标掩盖局部失效。

因此评估不能只看一次离线平均分。应使用独立测试集、压力测试、分布外测试和不同群体切片，部署前进行灰度或影子运行；上线后监测输入漂移、分群指标、延迟、错误率和资源占用，并设置置信度阈值、拒答、降级、人工接管及回滚机制。只有效果达到要求且在预期变化和故障下可控，才能称为稳定可靠。

评分要点

- 区分高指标与跨场景持续可靠。
- 说明真实环境中的分布、设备和系统变化。
- 提出离线测试、线上监控及安全降级措施。

第 2 题 数据规模与数据代表性

题目 解释为什么大量数据不一定带来性能提升，并说明代表性数据的意义。

参考答案

数据量增加只有在数据提供了新的、正确的有效信息时才可能提升性能。若新增样本重复度高、标签错误、噪声大，模型只是反复看到相同模式；若数据与任务目标不一致，数量越多反而越强化无关相关性。模型容量不足、特征或损失函数选择不当、类别严重不平衡、训练方法已经达到瓶颈时，单纯扩充数据也难以提高结果，甚至增加训练成本和过拟合偏差。

代表性是指数据能够覆盖系统实际服务的人群、场景、设备、时间、语言和少见但重要的边界情况，并大致反映真实条件下的变化。它不要求机械复制线上比例：对于罕见疾病、欺诈或安全事故，可以有意识增加样本，但评估时应恢复真实分布或使用适当权重。代表性决定模型学到的规律能否迁移，而总样本数只能说明规模。

实践中应先明确目标总体，再按类别、人群、地区、设备和时间分析覆盖率，检查标签一致性、重复样本和数据来源。训练、验证、测试还要按用户或时间等合理单位隔离，避免近重复样本泄露。与盲目追求数量相比，补充欠覆盖群体、困难样本和失败案例，改善标注质量并持续收集线上反馈，通常更能提高泛化能力。

评分要点

- 列出重复、噪声、偏移和模型瓶颈等原因。
- 说明代表性是对真实总体和边界场景的覆盖。
- 强调质量、覆盖和正确划分比单纯数量更重要。

第3题 面向文本的人工智能处理流程

题目 说明面向文本的人工智能系统从原始文字到输出结果的处理流程，重点解释文字如何转换成模型可处理的信息。

参考答案

系统首先接收原始文本并完成必要的清洗与规范化，例如处理编码、空白、特殊字符和敏感信息；对分类或抽取任务还要定义标签并制作训练样本。现代语言模型通常使用分词器把字符串切成 token。token 不一定等于一个汉字或单词，也可能是子词、标点或字节片段。分词器依据固定词表把每个 token 映射为整数编号，并加入开始、结束、分隔等特殊标记。

整数编号本身没有语义，模型通过嵌入层把它转换为连续向量。为了表示顺序，还会加入位置编码。Transformer 的自注意力层再根据上下文计算各位置之间的相关性，逐层形成带有语境的表示。文本分类系统可汇聚这些表示后输出类别概率；信息抽取系统为 token 预测实体或关系；生成系统则根据已有 token 计算下一个 token 的概率，反复采样或选择并续写。

输出编号最后由分词器解码回文字，再进行格式校验、敏感内容过滤、事实核验或业务规则检查。输入超过上下文窗口时需截断、分块、摘要或检索相关片段；批处理时还常用填充和注意力掩码区分真实 token 与补齐位置。完整流程可概括为文本规范化、token 化、编号与向量化、上下文建模、任务输出、解码和后处理。

评分要点

- 说明 token 化、词表编号、嵌入和位置编码。
- 解释注意力如何形成上下文表示。
- 覆盖任务输出、解码和后处理。

第 4 题 人工智能角色扮演的三种实现方案

题目 比较使用 prompt、微调和 skills 实现人工智能角色扮演的方式、优缺点和适用场景

参考答案

Prompt 方案是在系统提示或对话中直接写明身份、语气、知识边界和行为规则。它上线最快、成本最低，适合临时角色、原型和经常变化的设定；但提示会占用上下文，可能被用户输入稀释或注入攻击影响，长对话中的一致性也有限。改进方法是把角色规则放在高优先级提示中，使用结构化模板和示例，并对输出进行校验。

微调是用符合角色风格和任务要求的样本更新模型参数。它能让语言习惯和响应模式更稳定，推理时无需重复长提示，适合规模化、固定且有充足高质量数据的角色。然而训练、评估和版本维护成本较高，角色修改不够灵活；数据不足或偏差还会导致过拟合、知识遗忘和不当行为。微调也不能代替权限与安全控制。

Skills 可理解为可复用的任务说明、知识资源、脚本和工具流程，模型在需要时加载或调用。它适合让角色具备查资料、生成特定格式或操作业务系统的能力，更新某项技能比重重新训练模型容易，也便于审计；局限是依赖正确路由、工具权限和外部服务。实际系统常组合三者：**prompt** 定义角色与边界，微调稳定高频风格，**skills** 提供可更新的专业流程和工具能力。

评分要点

- 分别说明三种方案的机制。
- 比较成本、稳定性、可更新性和安全性。
- 指出组合使用时三者的分工。

第 5 题 生成式视觉模型与判别式视觉模型

题目 比较生成式视觉模型与图像分类、目标检测和图像分割模型的输入、输出及任务目标。

参考答案

生成式视觉模型学习图像分布或条件到图像的映射，目标是产生新的视觉内容。它可输入文本提示、噪声、参考图、掩膜或其他条件，输出一张或多张合成图像，也可完成扩图、修复和风格转换。例如文生图扩散模型从随机噪声逐步生成与提示匹配的像素。评价通常关注提示一致性、真实感、多样性和安全性，而不是识别某个固定答案。

图像分类、目标检测和分割主要属于识别或判别任务，输入通常是已有图像。分类输出整张图的一个或多个类别及概率，回答“是什么”；目标检测为每个物体输出类别、置信度和边界框，回答“有什么、在哪里”；分割为每个像素输出类别或实例归属，得到精确掩膜，回答“目标区域具体覆盖哪些像素”。其信息粒度依次从图像级、目标级到像素级。

两类模型都可以使用深度网络并从数据学习表示，但输出空间和错误含义不同。生成模型输出高维像素或视觉表示，可能产生不存在的细节；分类、检测、分割输出结构化判断，常见错误是错分、漏检、误检和边界不准。实际系统可以组合使用，例如先生成合成训练样本，再训练检测器，但必须防止生成偏差污染识别模型。

评分要点

- 写清生成模型的多种条件输入和图像输出。
- 区分分类标签、检测框和分割掩膜。
- 比较任务目标、指标与典型错误。

第 6 题 人工智能伦理与群体指标

题目 分析人工智能中的隐私、公平性和责任问题及应对措施。若总体性能上升但某个群体指标下降，能否称为系统性能提升？

参考答案

隐私问题包括未经充分同意收集数据、超范围使用、训练数据记忆以及输出泄露身份信息。应坚持目的限定和数据最小化，进行去标识化、访问控制、加密、保存期限管理和删除机制，并在高风险场景采用隐私评估或隐私保护训练。

公平性问题表现为不同群体的误报率、漏报率或服务质量差异，可通过改善数据代表性、按群体切片评估、调整阈值与流程、持续监测和提供申诉复核来缓解。

责任问题是系统出错后由谁解释、纠正和承担后果。组织应明确模型开发者、部署者和业务使用者的职责，保存数据版本、模型版本、决策依据和操作日志；高影响决定不能由模型单独完成，应设置人工监督、告知机制、可质疑渠道和事故响应流程。技术指标不能替代合规审查与管理问责。

总体性能上升但某个群体指标下降，不能无条件称为系统性能提升。总体平均值可能因多数群体占比大而掩盖少数群体受损，尤其当该群体承担更高漏诊、拒贷或误识别风险时。应同时报告总体指标、各群体指标、差距和不确定性，并依据预先规定的最低性能、公平约束和业务损害判断。只有总体收益真实、关键群体不低于安全底线，或退化有充分理由且配有补偿和复核措施，才可审慎上线。

评分要点

- 隐私、公平、责任均给出问题和措施。
- 指出平均指标会掩盖群体伤害。
- 用最低性能、公平约束和损害程度作判断。

第 7 题 数据标准化中的信息泄露

题目 某代码先在全部数据上拟合 `scaler`，再划分训练集和测试集，造成信息泄露。说明原因并给出正确顺序。

参考答案

标准化器在 `fit` 时会计算数据的均值、方差、最小值或其他统计量。若先对全部数据拟合，再划分训练集和测试集，测试集的信息已经进入这些统计量，相当于训练流程提前看到了本应未知的数据。虽然没有直接使用测试标签，评估条件仍被污染，得到的测试性能可能过于乐观，尤其在样本少、时间漂移或不同来源差异较大时。

正确顺序是先划分训练集和测试集；再仅在训练集上调用 `fit` 或 `fit_transform`；最后用同一个已拟合的 `scaler` 对验证集、测试集和未来线上数据调用 `transform`。若还要调参与选模型，应进一步从训练数据中划出验证集，任何根据数据学习的预处理步骤都只能在相应训练折中拟合。交叉验证时应把 `scaler` 与模型放入 `Pipeline`，确保每一折独立拟合。

参考代码

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train) # 只在训练集拟合
X_test_scaled = scaler.transform(X_test)      # 测试集只转换
```

评分要点

- 解释 `scaler` 的统计量如何泄露测试信息。
- 写出先划分、训练集拟合、其他集合只转换。
- 提及验证集或交叉验证中的同类原则。

第 8 题 三层多层感知机代码补全

题目 补全一个三层 MLP。输入维度为 `input_dim`，两个隐藏层维度分别为 `hidden1` 和 `hidden2`，输出维度为 `num_classes`；说明各层维度变换、激活函数以及 `forward` 流程。

参考答案

三层 MLP 通常指三个带参数的全连接层。第一层输入从 `input_dim` 映射到 `hidden1`，第二层从 `hidden1` 映射到 `hidden2`，第三层从 `hidden2` 输出 `num_classes` 个类别得分。前两个线性层后接 ReLU，引入非线性；若没有激活函数，多层线性变换等价于线性层，无法学习复杂决策边界。分类输出层通常不在 `forward` 中手动调用 `softmax`，因为 `CrossEntropyLoss` 已内部完成 `log-softmax`。输入 `x` 的形状应为 `batch_size×input_dim`；经过 `fc1`、ReLU 后为 `batch_size×hidden1`；经过 `fc2`、ReLU 后为 `batch_size×hidden2`；经过 `fc3` 后为 `batch_size×num_classes`。`forward` 按层调用并返回 `logits`。若原始输入是图像，应在进入 `fc1` 前展平除批次维外的维度，并保证展平后的特征数等于 `input_dim`。

参考代码

```
import torch
import torch.nn as nn
import torch.nn.functional as F

class ThreeLayerMLP(nn.Module):
    def __init__(self, input_dim, hidden1, hidden2, num_classes):
        super().__init__()
        self.fc1 = nn.Linear(input_dim, hidden1)
        self.fc2 = nn.Linear(hidden1, hidden2)
        self.fc3 = nn.Linear(hidden2, num_classes)

    def forward(self, x):
        x = F.relu(self.fc1(x)) # input_dim -> hidden1
        x = F.relu(self.fc2(x)) # hidden1 -> hidden2
        x = self.fc3(x)         # hidden2 -> num_classes
        return x                # logits
```

评分要点

- 三个 **Linear** 的输入输出维度首尾衔接。
- 前两层使用非线性激活函数。
- **forward** 返回 **logits**，并说明张量形状。

考前检查清单

- 高分不等于可靠，部署评估必须覆盖漂移、异常和降级。
- 数据价值由质量、代表性和独立划分共同决定。
- 文本依次经过 token 化、编号、嵌入、上下文建模和解码。
- 角色扮演可用 prompt、微调和 skills 分工组合。
- 生成模型输出图像，分类、检测、分割输出结构化判断。
- 平均性能必须结合群体指标和安全底线解释。
- 任何会从数据学习参数的预处理都应只在训练集拟合。
- MLP 各层维度必须衔接，隐藏层需要非线性激活。

第四套【回忆版】考题

题目来源：20260909 下午自动化专业考题回忆版

第1题 预测正确与理解正确

题目 说明 AI 预测正确与理解正确的差异，从因果角度解释重大决策为什么需依据和限制。

参考答案

AI 预测正确是指它在某个样本上给出了与标准答案一致的结果，可能源于真正抓住了任务规律，也可能只是利用数据中的表面相关、捷径特征或偶然性。例如模型看到医院标记就预测患病，在原测试集上可能正确，但换一家医院便失效。理解正确要求系统形成与对象、关系和情境相符的内部表示，知道结论在什么条件下成立，能迁移到新场景，并对反例和条件变化作出合理反应。因此一次答对不能证明理解。

因果关系回答干预某个因素会不会改变结果，相关关系只说明两个现象同时出现。重大决策如诊疗、信贷和司法若依据伪相关，环境一变就可能伤害当事人。人们希望 AI 给出依据，是为了核对证据是否真实、是否与结论相关、是否存在替代解释，并让专业人员发现模型是否依赖了性别、地区等不应决定结果的特征。

同时，解释必须说明限制：适用人群、数据来源、置信度、未覆盖情形和不能推出的因果结论。系统可提供引用证据、关键特征、反事实测试和不确定性，但这些都不自动等于真实因果解释。高风险场景仍需因果研究、外部验证、人工复核和申诉机制。可靠的表述应是“在这些条件和证据下支持该建议”，而不是把预测包装成确定原因。

评分要点

- 区分单次命中、相关捷径与可迁移理解。
- 说明相关不等于因果，干预与条件变化是关键。
- 写出证据、限制、不确定性和人工复核。

第 2 题 神经网络训练流程与损失排查

题目 说明神经元、权重、激活函数、损失函数、反向传播和参数更新的作用；用一句话概括神经网络流程，并分析训练 loss 长期不降或曲线变平的原因。

参考答案

神经元接收上一层输入并计算加权和；权重和偏置是从数据中学习的参数，决定各特征影响；激活函数如 ReLU 引入非线性，使网络能表示复杂关系。损失函数衡量预测与真实标签的差距，为训练提供优化目标。反向传播依据链式法则计算损失对各参数的梯度，优化器再按梯度和学习率更新参数，使下一次预测通常更接近目标。

一句话概括：输入经过各层的线性变换与非线性激活得到预测，损失函数计算误差，反向传播求梯度，优化器更新权重并反复迭代。若 loss 一开始就不降，应先查数据和代码：标签是否错位、数值是否归一化、类别是否极不平衡，loss 与输出是否匹配，是否遗漏 zero_grad、backward 或 step，参数是否被冻结，训练模式和设备是否正确。

若 loss 下降后变平，可从优化和模型能力判断：学习率过小导致进展慢，过大则震荡；激活饱和、梯度消失或初始化不当会阻碍传播；模型容量不足、正则化太强或特征信息不足会形成欠拟合。还应比较训练与验证曲线：两者都高且平说明欠拟合或优化失败；训练继续下降而验证不改善说明过拟合或分布差异。检查梯度范数、不同 batch 的损失、基线模型和少量样本能否过拟合，可快速定位问题。

评分要点

- 完整说明六个训练要素。
- 用一句话串联前向 损失 反向 更新。
- 从数据 代码 优化 模型和验证曲线多角度排查。

第 3 题 文本分类与信息提取

题目 说明文本分类和信息提取的含义与输入输出，使用同一文本举例，并解释整合系统如何联合利用二者。

参考答案

文本分类把一段文本整体映射到预定义类别，输入是句子、评论、邮件或文档，输出是一个或多个类别及置信度，例如情感正负、新闻主题或工单类型。信息提取则从文本中找出结构化事实，输入仍是自然语言，输出可以是实体、属性、时间、地点、关系或事件，通常保留其在原文中的位置。前者回答“这段话属于什么”，后者回答“文中具体提到了什么”。

例如文本“张女士反映 9 月 8 日购买的 A 型手机无法充电，希望在上海门店退货”。分类模型可输出“售后投诉 / 退货请求”；信息提取模型可得到客户=张女士、日期=9 月 8 日、产品=A 型手机、故障=无法充电、地点=上海门店、诉求=退货。这说明同一输入可以同时产生文档级标签和字段级结构化结果。

在整合系统中，可先用分类结果决定处理路线，把该文本送到售后流程；再用提取结果自动填写工单字段、查询订单、匹配退货规则并生成回复。也可并行运行后做一致性校验：若分类为“咨询”但提取到“退货”，则降低置信度或转人工。分类提供宏观意图，信息提取提供执行所需参数，二者与规则、知识库和人工复核结合，才能把理解转化为可追踪的业务操作。

评分要点

- 明确两类任务的输入输出和回答问题。
- 用同一文本分别给出标签和实体字段。
- 说明分类负责路由 提取负责填参与执行。

第 4 题 多模态信息融合与对齐

题目 解释多模态信息融合和对齐，并制定多数据源冲突的处理策略，涵盖可靠性、置信度和一致性。

参考答案

多模态对齐是建立不同信息形式之间的对应关系，例如把视频帧中的说话人与语音片段、字幕时间和文本含义对应起来，解决“谁在何时表达了什么”。多模态融合是在完成必要对齐后，联合利用图像、语音、文本、传感器等信息形成更完整的表示或决策。融合可以在输入特征层、模型中间表示层或最终决策层完成，不同方式在信息保留、计算量和可解释性上不同。

数据源冲突时不应简单平均。系统应先检查时间戳、坐标系、单位、身份和采样频率，排除错位；再为来源建立可靠性档案，包括历史准确率、设备状态、数据新鲜度和是否可被篡改。模型置信度必须经过校准，不能把未经校准的概率直接当可信程度。若两个来源独立且质量相近，可按可靠性加权；若某来源明显过期、故障或低质量，应降权或舍弃。

还需制定冲突等级与处置规则：低风险冲突可选择最新或高可信来源并记录依据；中等风险可请求额外模态、重新采样或进行一致性检验；高风险决策在关键来源不一致时应暂停、拒答或转人工。评估时分别报告单模态性能、缺失模态性能、冲突样本性能和群体差异，并保留来源、置信度、对齐误差和最终决策日志。这样可防止一个高噪声信号拖累整个系统。

评分要点

- 区分对齐的对应关系与融合联合决策。
- 冲突策略包含校时 单位 来源可靠性和置信度校准。
- 按风险分级处理并保留审计记录。

第 5 题 人工智能安全风险评估

题目 说明 AI 面临的主要安全风险，如何建立风险评估体系，并举例说明明确的安全检测机制。

参考答案

AI 安全风险包括输入侧的提示注入、越狱、对抗样本和数据投毒；模型侧的幻觉、偏见、隐私记忆、分布外失效与不可控工具调用；系统侧的身份认证不足、权限过大、供应链漏洞和敏感数据泄露；输出侧还可能产生有害内容、错误代码或高风险决策。智能体能调用邮件、数据库或支付工具时，模型错误会进一步变成真实操作，因此风险必须按资产、攻击面和后果分析。

风险评估应先明确系统用途、用户、数据、工具权限和不可接受后果，再建立威胁模型，列出攻击者能力和故障路径。随后用发生可能性与影响程度分级，制定安全指标和上线门槛，并在正常、异常、恶意和分布外样本上测试。上线前需要红队测试、权限审查和应急演练；上线后监测输入输出、工具调用、异常率和漂移，保留日志，定期复评模型及依赖版本。

明确机制例如工具调用的“策略网关”：模型生成调用请求后，系统不直接执行，而是检查调用者身份、参数格式、工具白名单、最小权限、金额或数据范围；高风险操作要求人工二次确认，并用沙箱、速率限制和审计日志约束。针对提示注入，还可把外部文档视为不可信数据，隔离其指令，使用攻击测试集统计绕过率。检测失败时系统应拒绝、降级或回滚，而不是只给出警告。

评分要点

- 覆盖输入 模型 系统 输出和工具风险。
- 风险评估包含用途 威胁 分级 测试 上线监控。
- 给出可执行的检测 拦截和失败处置机制。

第 6 题 像素通道分辨率与计算成本

题目 解释像素、RGB 通道和分辨率，并说明分辨率增加为什么会使视觉模型计算成本明显上升。

参考答案

像素是数字图像的基本空间采样单元，每个像素记录某个位置的颜色或亮度。RGB 图像通常用红、绿、蓝三个通道表示颜色，因此一张高度为 H 、宽度为 W 的图像可表示为 $H \times W \times 3$ 的数值张量。分辨率通常指图像的宽和高，例如 1920×1080 ，像素总数为两者乘积；位深则决定每个通道可表示的数值范围，不应与分辨率混淆。

当宽和高同时扩大 k 倍时，像素数量不是增加 k 倍，而是增加 k^2 倍。例如 224×224 放大到 448×448 ，边长翻倍，像素和三个通道中的输入数值总量变为四倍。卷积层要在更多空间位置上执行乘加运算，中间特征图也随之增大，因此计算量、显存占用、数据读取和传输开销通常都显著上升。更深网络还会在多层重复这种成本。

对 Vision Transformer，图像被划分为 patch。若 patch 大小不变，边长翻倍会使 token 数量变为四倍；标准全局自注意力的两两关系计算近似与 token 数平方成正比，注意力部分甚至可能增长约十六倍。实际增幅取决于下采样、窗口注意力、批大小和模型结构。可通过缩放输入、裁剪感兴趣区域、增大 patch、使用多尺度或稀疏注意力降低成本，但过度压缩会丢失小目标和细节。

评分要点

- 准确定义像素 RGB 张量和分辨率。
- 说明边长倍增导致像素量平方增长。
- 比较卷积和自注意力的计算 显存代价。

第 7 题 神经网络测试模式纠错

题目 某含 Dropout 或 BatchNorm 的 PyTorch 模型训练后直接在测试集循环中推理，（1）代码有什么主要问题（2）给出正确代码（3）说明 `model.eval()` 的重要性。

```
model.eval()
correct = 0
total = 0

with torch.no_grad():
    for x, y in test_loader:
        x = x.to(device)
        y = y.to(device)
        outputs = model(x)
        predicted = outputs.argmax(dim=1)
        total += y.size(0)
        correct += (predicted == y).sum().item()

accuracy = correct / total
print("Test accuracy:", accuracy)
```

参考答案

主要问题是模型仍处于训练模式且推理时建立梯度图。训练模式下 Dropout 会继续随机丢弃神经元，同一输入多次预测可能不同；BatchNorm 会使用当前批次统计量并可能更新运行统计量，测试结果会受批大小和样本组成影响。未使用 `torch.no_grad()` 通常不改变预测数值，但会保存反向传播所需中间结果，增加显存和计算开销。若模型在 GPU 上，还必须把输入和标签放到相同设备。

`model.eval()` 会递归把相关模块切换到评估行为，但它不会关闭梯度；`torch.no_grad()` 会关闭梯度记录，却不会改变 Dropout 或 BatchNorm 的模式，因此二者不能互相替代。测试结束后若还要继续训练，应再次调用 `model.train()`。正式评估还要保证预处理、类别顺序、阈值和权重版本与预期一致，并用正确的分母计算指标。

评分要点

- 指出训练模式和梯度记录两个问题。
- 代码包含 `eval no_grad` 和设备迁移。
- 解释 `eval` 对 Dropout BatchNorm 的作用及其与 `no_grad` 的区别。

第 8 题 精确率召回率和 F1 计算

题目 已知 TP、TN、FP、FN，写出 precision、recall 和 F1 的计算公式，并说明各指标含义及边界处理。

参考答案

TP 是实际为正且预测为正，TN 是实际为负且预测为负，FP 是实际为负但误报为正，FN 是实际为正但漏报为负。

Precision = $TP / (TP + FP)$ ，表示所有被模型判为正的样本中有多少为正，衡量误报；

Recall = $TP / (TP + FN)$ ，表示所有真正例中有多少被检出，重点衡量漏报。

$F1 = 2 \times \text{precision} \times \text{recall} / (\text{precision} + \text{recall})$ ，等价于 $2TP / (2TP + FP + FN)$ 。调和平均会惩罚其中一个指标很低的情况，因此适合需要兼顾误报与漏报的任务。若更重视召回率或精确率，可使用带权的 $F\beta$ ，而不是只看 F1。

评分要点

- 写对 precision recall F1 及等价式。

考前检查清单

- 预测命中不等于理解，重大决策要交代证据 条件和限制。
- 神经网络流程是前向预测 计算损失 反向求梯度 更新参数。
- 分类负责整体标签，提取负责结构化字段，二者可联合路由。
- 多模态冲突先校准对齐与来源，再按可靠性和风险处置。
- AI 安全需要威胁建模 检测拦截 监控和失败降级。
- 图像边长翻倍意味着像素数量变为四倍。
- 推理必须正确组合 model.eval() 和 torch.no_grad()。
- Precision 关注误报，Recall 关注漏报，F1 平衡二者。