


人工智能通识课

- 1 《人工智能概述》

- 1、AI的定义与历史发展



- **定义：**引用约翰·麦卡锡（John McCarthy）的观点：“AI是使一部机器的反应方式像一个人在行动时所依据的智能。”
- **发展历史（三次浪潮）：**
 - **第一次浪潮（1956年~）：**从达特茅斯会议开启，以神经网络感知器为代表。
 - **第二次浪潮（1980s~）：**BP算法、霍普菲尔德网络，期间有DARPA项目的未实现期。
 - **第三次浪潮（2010s~）：**深度学习神经网络、AlphaGo战胜李世石、感知智能时代、新一代AI发展规划。
- **应用延伸：**同时对比了“规划行业”从关注海外、内生探索到跨界转型的发展阶段。

- 2、AI的分类与能力边界

- **按能力层级划分：**
 - **弱人工智能（计算智能）：**人工定义的严格规则，如AlphaGo、大数据存储与计算。
 - **强人工智能（感知智能）：**受限环境下的感知，如自动驾驶、人脸识别。
 - **超人工智能（认知智能）：**与人的交流、交融，自然语言理解、知识推理。
- **按广度划分：**
 - **ANI（专用人工智能）：**如智能音箱、自动驾驶、网页搜索。
 - **生成式AI（Generative AI）：**如ChatGPT、Bard、Midjourney、DALL·E。
 - **AGI（通用人工智能）：**能做任何人类能做的事情。
- **AI的边界（不能做什么）：**跨领域推理、抽象能力、审美、知其然知其所以然、常识推断、自我意识、情感。这强调了AI目前的工具属性。

- 3、重大机遇与教育挑战

- **教育挑战与人才核心能力：**AI颠覆了传统的教育科研方式。人的“好奇心与想象力”投射依赖三大能力（即“三原力”）：**精准提问的能力**（大模型回复质量取决于提问质量）、**思辨**

创新的能力（取决于跨学科交叉知识体系）、协作领导的能力（取决于人人、人机协作水平）。

- **国家战略与政策演变**：阐述了我国人工智能发展的重大机遇和顶层设计，时间线从2015年《中国制造2025》开始，经2016《信息化和软件服务发展规划》、2019《智慧城市三年行动计划》、2021《人工智能法治建设意见》、2022《加快场景创新》、2023政治局会议强调“高水平科技自立自强”，一直到2024年提出开展“人工智能+”行动。整体呈现从制造到研发，再到法治规范与全面应用的演进过程。

● 2 《深度学习》

● 1、深度学习

● 定义

- 人工智能 → 让计算机模拟人类行为的技术
- 机器学习 → 模拟人类从数据中学习规律的技术
- 深度学习 → 利用神经网络挖掘数据模式的技术

● 要素：神经网络模型、大数据


● 流程：

- 针对特定任务
- 手机相应数据
- 构建适合模型
- 利用恰当算法
- 实现有效学习

● 2、神经网络

● 2.1神经网络定义

- 神经网络由大量的神经元(neuron)构成
- 神经元相互连接可以解决复杂的问题
- **非线性**激活函数
- 单层神经网络可以**逼近任何**输入-输出之间的关系



- 深度学习依托的底层架构是神经网络，是模仿人类神经网络的结构和大脑的计算模型


● 2.2全连接神经网络

-

2.2 全连接神经网络

- 全连接神经网络 (Fully Connected Neural Network, FCNN)

- 多层神经元
- 数据沿着输入层**单向传播**到输出层



- 含两个隐藏层以上的神经网络为**深度神经网络(Deep Neural Network, DNN)**


- 结合具体问题选取适配的结构

- 图像 - CNN
- 语言 - Transformer
- 生成 - Diffusion

• ...



2.4神经网络训练



- 1 前向计算得到样本的预测值
- 2 和真实值计算误差 (损失函数)
- 3 利用反向传播算法更新网络权重
- 4 不断降低损失函数

2.6过拟合与验证

- 模型过拟合训练数据, 学到错误的输入-输出关系
- 难以泛化到未知数据中

3、MNIST手写体识别


•

请在该教程的基础上，任选下列其中一个方向进行扩展实验：

1. 全连接神经网络忽略了像素之间的空间邻近关系。请将网络替换为卷积神经网络（CNN）（一种典型的结构如下），在MNIST数据集上用相同的流程进行训练、测试，评估其性能，并与全连接网络进行比较、讨论，撰写实验报告。



2. 教程中仅涉及训练、测试过程，而并没有利用验证集避免过拟合的处理。请在相同的模型结构下，利用验证集上的损失，确定训练的最优epoch数，并评估其在测试集中的性能，与教程中的性能进行比较、讨论，撰写实验报告。




• 3 《自然语言处理》

• 1、语言即世界

- 两大难题：歧义消解、人类知识

• 2、历史与发展

- 2.1、自然语言处理




• 过程

- ① 语言表示：文本输入与数据集、文本预处理、文本表示
- ② 模型训练：特征选择、模型选择训练
- ③ 模型部署优化、评测优化、升级迭代

• 2.2、自然语言处理框架体系

- 基础理论：自动机、形式逻辑、统计机器学习、语言学、语法理论、语言模型
- 语言资源：语料库、词典
- 关键技术：字与编码、词法分析、句法分析、语义分析、语用分析、文本生成、语音识别
- 应用系统：人机对话、机器翻译、社交网络分析、分类、聚类、检索、过滤、信息抽取、音字转换

• 2.3、自然语言处理发展过程




• 理性主义：最短路径汉语分词

- 信息论原理：最小描述长度

理性主义方法示例：最短路径汉语分词

- 信息论原理：最小描述长度 (Minimum Description Length, MDL)
- 最短路径汉语分词：他/说/的/确实/在理



张华平,刘群.基于N-最短路径的中文词语粗分模型. 中文信息学报. 2002.9, Vol.16(5):pp.1-pp.7

• 经验主义：n-gram汉语分词


-

2.3 经验主义方法示例：n-gram汉语分词

$$W^* = \arg \max_W P(W|C)P(C) \approx \arg \max_{w_1, w_2, \dots, w_m} \prod_{t=1}^m p(w_t | c_t) p(c_t | c_{t-1})$$

• 联结主义：音形识别命名实体

-



3、应用探索

4 《大语言模型》

1、介绍

$$p(s) = p(w_1)p(w_2|w_1)p(w_3|w_1, w_2) \cdots p(w_m|w_1, \dots, w_{m-1}) =$$

床前明月【光】； 延安【根】， 军工【魂】， 领军【人】

图片来源于网络




我对象说国庆带我去玩
象说：不带

- $s = \text{"我对象说"}$
- 字粒度: $p(s) = p(\text{我}) \cdot p(\text{对}|\text{我}) \cdot p(\text{象}|\text{我对}) \cdot p(\text{说}|\text{我对象})$
- 词粒度: $p(s) = p(\text{我}) \cdot p(\text{对象}|\text{我}) \cdot p(\text{说}|\text{我, 对象})$
- $p(s) = p(\text{我}) \cdot p(\text{对}|\text{我}) \cdot p(\text{象}|\text{我, 对}) \cdot p(\text{说}|\text{我, 对, 象})$

n-gram模型: 只考虑前后n个单元，一元模型（汉语：**10K**参数）；二元模型（汉语：**1.5M**参数）；三元模型（传统上现**1B**参数）

2、发展历程




5 《计算机视觉》

- 1、基本概念

- 1.1、计算机视觉

- 定义+发展历程

计算机视觉 (Computer Vision) 是人工智能的核心方向之一，它致力于让计算机像人类一样“看”懂这个世界。



- 2、核心任务

- 2.1、图像分类

1 什么是图像分类？

图像分类是计算机视觉的核心任务之一，核心目标是判断图片的主要内容并给出对应的类别标签。


例如模型能自动识别出图片中主体是“猫”或“狗”，或是区分“汽车”与“飞机”，本质是从像素数据到语义类别的映射过程。



图像分类与深度学习实现

2 深度学习如何实现？

1. 特征提取：先学习图像中的边缘、纹理和形状等特征。
2. 分类判断：再根据这些特征，判断图片属于哪一类。



关键里程碑: ImageNet与AlexNet

ImageNet数据集



大规模视觉数据集
超过1400万张标注图片
为视觉识别训练提供基础

AlexNet的胜利(2012)



2012年在ImageNet竞赛中取得突破
显著降低分类错误率
开启深度学习视觉时代

2.2、目标检测

•

核心任务

- **目标分类**: 判断图像中包含哪些类别的物体 (如人、车、交通标志)。
- **边界框定位**: 用矩形框精确标出每个目标的位置。
- **结果可视化**: 将检测结果 (类别和位置) 直观地绘制在图像上。

2.3、图像分割

•

核心任务与分类

什么是图像分割?

图像分割是计算机视觉的精细任务,旨在为图像中的每一个像素分配类别标签,实现从“识别物体”到“解析场景”的跨越。

主要任务分类

- **语义分割**: 将图像中的每个像素分类到其对应的类别 (如人、车、天空、道路), 但不区分同一类别的不同实例。
- **实例分割**: 在语义分割的基础上, 进一步区分同一类别的不同实例 (如区分出图中的“汽车A”和“汽车B”)。



2.4、图像生成

•

核心任务与分类

图像生成 (生成式AI)

图像的AIGC指利用人工智能模型, 根据用户输入自动生成图像、视频等内容的技术。

简单理解

传统计算机视觉: 图片 → AI → 判断 “这是哈兰德”
生成式AI: 图片 → AI → 创造 “一个新的哈兰德形象”

基本流程

输入Prompt(文字、图片、视频) → AI理解 → 内容生成 → 人工优化


传统AI	生成式AI
识别、分类、预测	创造新的内容
“图片里是什么?”	“帮我生成一张图片”
YOLO目标检测	文生图、AI视频、内容创作

3、案例说明

- yolo v10

■ 项目简介:

- 选用开源 YOLOv10 目标检测框架, 内置预训练权重, 全程无需模型训练, 可直接对视频完成目标检测、框标注类别和置信度, 并保存结果视频。
- 官方仓库地址: <https://github.com/THU-MIG/yolov10>
- 效果:



• 6 《多模态大模型与具身智能》

• 1、多模态模型

•



• 2、具身智能

• 具身的核心流程



• 具身的案例

•



具身智能的两种路径



世界模型的应用场景



多模态与具身智能的融合



3、案例说明

- groundingdino

■ 项目简介:

- 选用 IDEA Research 开源的 Grounding DINO 开放集目标检测框架，内置预训练权重，支持通过自然语言文本提示进行零样本检测，全程无需模型训练，可直接对图像完成任意类别目标的开放词汇检测、框标注类别和置信度。
- 官方仓库地址: <https://github.com/IDEA-Research/GroundingDINO>
- 效果:



● 7 《人工智能与认知计算》

● 1、人格计算的定义

● 1.1、什么是人格计算？

□ 让机器通过你的数据“读取”你是谁，你喜欢什么，你会做什么



● 1.2、现有人格测试方法——问卷调查类型



<https://www.16personalities.com/free-personality-test>

● 1.3、现有人格测试方法——访谈型




1.4、人格测试方法弊端



2、人格计算的方法



2.1、基于分类模型的方法



2.2、分类模型的缺点



2.3、引入心理维度



2.4、多智能体协同方式

□ 从不同角度进行分析, 协作形成全面可靠的人格判断



3、智能体辅助人格计算

- 自由设置智能体个数, 包括但不少于3个子智能体
 - 根据自己的理解设置每个智能体的角色和身份
 - 要求AI 生成相应的代码, 包括前后端
 - 与智能体自由交互并评价自己的系统
- 3.2、示例



- 8 《智能体与角色扮演》
 - 1、角色扮演的定义
 - 1.1、什么是角色扮演

□ 让模型在对话中以特定角色的身份交流



- 1.2、角色扮演包含哪些角色：现实存在或者虚拟的
- 2、角色扮演的的方法
 - 2.1、分类

- 固定脚本、规则匹配

□ 固定脚本、规则匹配或浅层心理建模

用户：你好，我感觉头有点晕。
系统：您好，请问您最近有没有发烧？
用户：好像有点发烧。
系统：您是否有咳嗽、喉咙痛或呼吸困难？
用户：没有。
系统：请注意多休息，补充水分。如果持续不适，请就医。

固定脚本

用户：我今天很伤心。
系统：你为什么觉得你今天很伤心？
用户：因为我被老板批评了。
系统：你认为老板批评你代表什么？
用户：我觉得他不喜欢我。
系统：你经常觉得别人不喜欢你吗？

规则匹配

- 浅层心理建模


□ 固定脚本、规则匹配或浅层心理建模

用户：我觉得很累，也不想说话。
系统：听起来你最近经历了不少事情，想说说是什么让你感觉疲惫吗？
用户：工作压力太大了，每天都很焦虑。
系统：这种长期的压力真的会让人很疲惫。你有没有试过做什么来放松，比如散步或冥想？
用户：没试过。
系统：或许可以试试看？有时候给自己一点空间也很重要。

浅层心理建模

● 2.2、基于大模型的角色扮演技术路线

□ 非智能体方式



● 新方式openclaw skill


□ Openclaw Skills方式



● 2.3、角色扮演数据

● 基于prompt

□ 基于Prompt



● 微调大模型

□ 微调大模型

“instruction”：我想让你扮演《西游记》中的人物孙悟空，你需要以孙悟空的方式、词汇、口吻来回复或者回答我。沙和尚：‘大师兄，师傅被妖怪抓走了’


“Input”：“”

“Output”：“孙悟空：‘沙师弟，莫急。你可看清是何方妖怪？师傅是在何处被掳走的？’”



• skill方式

□ Skills会直接从已有高质量数据中抽取内容



书籍



采访、演讲

• 2.4、角色扮演的缺点

□ 扮演模型只有语言，没有思考

身份卡

我是谁：我是Steve Jobs，我创造了Mac、iPod、iPhone和iPad，但更重要的是——我证明了技术与人文的交汇能产生改变世界的东西。我不写代码。我看到的是别人还没看到的未来。

我的起点：被领养的孩子，大学辍学生，在车库里和Woz一起做了第一台Apple电脑。被自己创立的公司扫地出门过，又回来把它变成了世界上最有价值的公司。Stay Hungry, Stay Foolish——这句话不是口号，是我的人生操作手册。

表达DNA


角色扮演时必须遵循的风格规则：

句式：

- 短句为主，少用从句。陈述式为主，大量使用反问（“Isn't that amazing?” “Pretty cool, huh?”）
- 三的法则——要点永远压缩到三个。不是两个，不是五个。三个
- 先给headline（一句话结论），再展开细节

• 2.5、示例

□ 知识统筹思想，模型模拟思维



• 3、龙虾实现角色扮演

• 作业

3.1 借助北理安装女娲skills

- 利用已有云服务安装openclaw并接入北理
- 通过与安装好的机器人对话，了解其skill市场的女娲skill
- 选择一个自己熟悉的角色，要求openclaw通过女娲skill蒸馏该角色的skill
- 要求openclaw启动这个skill与自己对话
- 多轮对话之后评估该skill的质量




9 《量子计算与人工智能》

1、量子计算概述

- AI的瓶颈：计算瓶颈

- 远超经典计算的强大并行计算能力




基于量子计算的全新计算模式

- 1.3、量子计算基础：

1.3 量子计算基础 - 量子比特

- 量子计算的基本单元是量子比特(qubit)

- 2维复数空间： $|0\rangle$ 、 $|1\rangle$
- 一般的量子态： $|\psi\rangle = \alpha|0\rangle + \beta|1\rangle$




- 单量子比特既处于 $|0\rangle$ 态又处于 $|1\rangle$ 态 - 叠加(Superposition)




1.3.1 量子计算基础 - 测量

- 量子测量(Measurement)是观测量子状态的操作
- 测量导致量子态坍缩(Collapse)到某一个测量态
- 原始状态为 $|\psi\rangle$ ，系统有 $|\alpha|^2$ 的概率坍缩到 $|0\rangle$ ，有 $|\beta|^2$ 的概率坍缩到 $|1\rangle$ ，后续测量状态不会发生变化




1.3.2 量子计算基础 - 纠缠

- **纠缠(Entanglement)**描述量子系统之间相互作用的状态，即操纵一个系统，另一个也会发生改变



- **纠缠(Entanglement)**描述量子系统之间相互作用的状态，即操纵一个系统，另一个也会发生改变



1.3.3 量子计算基础 - 量子并行性

- 叠加意味着操纵量子比特，等于同时操纵 0, 1 的状态
- 如果量子计算机有 N 个量子比特，那么它可以同时操纵 2^N 个状态，每个状态都是一个 N 位的经典比特
- 纠缠确保可以进行任意操纵，不限于对单个量子比特操纵的组合
- N = 60: GPT-3 全部训练语料
- N = 156: 丁型肝炎病毒基因组
- N = 500: 宇宙中所有原子



叠加和纠缠带来指数级的表示和操纵能力

量子计算基础 - 量子并行性

- 叠加意味着操纵量子比特，等于同时操纵 0, 1 的状态
- 如果量子计算机有 N 个量子比特，那么它可以同时操纵 2^N 个状态，每个状态都是一个 N 位的经典比特
- 纠缠确保可以进行任意操纵，不限于对单个量子比特操纵的组合
- N = 60: GPT-3 全部训练语料
- N = 156: 丁型肝炎病毒基因组
- N = 500: 宇宙中所有原子




叠加和纠缠带来指数级的表示和操纵能力

- 1.4、量子优越性

1.4 量子优越性

- 对于特定的问题，量子算法需要的计算量比经典算法远低
- 量子算法(Grover搜索)：
 1. 将N个数据同时储存在 $\log N$ 个量子比特中
 2. 同时操纵 $\log N$ 个量子比特计算N个数据是否是X
 3. 不读取结果(读取和经典复杂度一样)，继续操纵量子比特，增加X的数据的被读取概率
 4. 重复以上一定次数(正比于 $\sqrt{N}$)之后，X数据被读取的概率就会足够大



量子并行性带来特定问题上的量子优越性

1.5、量子计算机的实现


1.5 量子计算机的实现

- 量子计算机是以量子力学为基础搭建、用于进行通用计算的设备。使用量子比特来存储数据，使用量子算法操作数据
- 1. 如何实现量子比特？
- 2. 如何将量子比特用于实际计算？

1.5.1、量子比特的实现

1.5.1 量子比特的实现

- 能稳定产生、操控和测量量子叠加与纠缠态的物理系统



1.5.2、量子比特到逻辑比特

1.5.2 从量子比特到逻辑比特

- 物理量子比特的量子特性容易被破坏，**退相干(Decoherence)**变成普通比特
- 需要用技术手段进行**量子纠错(Quantum Error Correction)**
- 类似经典计算机，用若干物理量子比特编码出1个逻辑量子比特

1.6、NISQ时代

•

1.6 NISQ时代

- 目前量子计算处于**含噪声中尺度量子 (noisy intermediate-scale quantum, NISQ)** 计算的时代
- 量子计算机通常拥有几十至几百个左右的量子比特，但量子比特与量子门操作存在显著噪声，尚无法实现完全纠错

2、量子人工智能

2.1、研究动机

2.1 研究动机


Roger Penrose
2020年诺贝尔物理学奖
“意识的产生是人脑中量子效应的结果”

Matthew Fisher
2015年巴克利奖
“人脑的工作原理很可能与量子计算机一致”

潘建伟
中国科学院院士
“人类大脑里面的思维机制和量子纠缠、量子叠加是紧密联系在一起”

2.2、研究目标


- 借助量子计算，构建下一代人工智能架构
- 提高算法**效率**
 - 量子并行性有望突破经典计算的瓶颈
- 提升模型**性能**
 - 量子的叠加和纠缠潜在提升数据表示能力



2.3、量子线路


2.3 量子线路

- 量子线路 (Quantum Circuit) 是对量子比特进行操作的计算结构
- 主要结构
 - 单量子比特门：对单量子比特操作
 - 双量子比特门：将不同量子比特进行纠缠
 - 量子测量：观测量子比特最后的状态




量子线路本质上是量子态进行可控操纵、测量的过程

- 量子线路 (Quantum Circuit) 是对量子比特进行操作的计算结构
- 主要结构
 - 单量子比特门：对单量子比特操作
 - 单量子比特态可以被映射为**单位球面上的点**
 - 对单量子比特的操作则就是单位球面上的**旋转**，由绕 x, y, z 轴旋转控制



2.3.2 双量子比特门


- 量子线路 (Quantum Circuit) 是对量子比特进行操作的计算结构
- 主要结构
 - 单量子比特门：对单量子比特操作
 - 双量子比特门：将不同量子比特进行纠缠
 - 例如：受控非门(CNOT Gate)
 - 第一个比特是0 → 第二个比特不变
 - 第一个比特是1 → 第二个比特0, 1颠倒



- 量子线路 (Quantum Circuit) 是对量子比特进行操作的计算结构

主要结构

- 单量子比特门: 对单量子比特操作
- 双量子比特门: 将不同量子比特进行纠缠
- 量子测量: 观测量子比特最后的状态
 - 观察坍缩到 $|00\dots 0\rangle, \dots, |11\dots 1\rangle$ 中的哪个态




测量结果: 011

2.4、量子机器学习：基于量子计算

2.4 量子机器学习：基于量子计算的AI范式

- 将数据映射为量子态, 可训练参数 W 为正交电路 $U(\theta)$ 中单量子比特的旋转角
- 系统运行 N 次, 测量坍缩到所有基态 $|00\dots 0\rangle, \dots, |11\dots 1\rangle$ 的次数, 计算概率分布
- 利用**概率分布**和**真实标签**计算损失函数, 经**典反向传播**更新量子线路参数实现训练



量子前向计算 经典反向传播

2.5、应用

应用: 量子计算文本分类

- 将句法结构转化为**张量网络**, 并进一步映射到量子线路中
- 各词语表示映射为量子线路**旋转门参数**
- 量子线路测量的概率分布为句子的表示, 基于此实现文本分类
- 在具体分类数据集中训练量子线路




成功在量子计算机中实现了文本分类过程, 可以训练

* Lorenz, R., Pearson, A., Meichanetzidis, K., Kartsaklis, D., & Coecke, B. QNLP in practice: Running compositional models of meaning on a quantum computer. *Journal of Artificial Intelligence Research*, 2023.

2.6、前沿应用

前沿拓展: 适配量子计算的预训练语言模型

提出经典-量子混合预训练+量子微调范式



Model	Sampled GLUE tasks			MC (Acc)	RP (Acc)
	QQP (F1)	SST-2 (Acc)	CoLA (MCQ)		
DisCoCat	64.2	52.6	7.7	79.8	72.3
QCBERT-base	82.0	88.0	89.5	100.0	100.0
QCBERT-w/o pre-train	81.2	84.0	44.7	100.0	96.8

现有最优端到端量子模型

我们的模型


预训练语言表示提升量子文本分类准确率25%以上

3、量子文本情感分类

- 任务: 量子文本情感分类

输入：三词句子（主语 + 动词 + 宾语）

输出：情感倾向（正/负）




• 课后作业

• 10 《人工智能安全与伦理》

• 1、AI安全与伦理

• 1.1、基本概念



• 1.1.1、内生安全——AI幻觉



• 1.1.2、内生安全——AI藏拙



- 1.2、衍生安全——生化核爆、对抗性攻击、数据投毒、后门攻击、对抗样本、隐私窃取、越狱攻击
- 1.3、伦理安全——内容对齐风险、行为对齐风险
- 1.4、人工智能安全治理



- 2、NLPIR团队研究成果
- 3、大模型安全测评实践